

机器学习工程实践报告：Simsnap 调研

余筱涵, 侯昱晨, 潘思余

1. 实验环境说明

笔者基于 Anaconda 进行实验, python 版本 3.9, CUDA 版本 v11.4。
运行实验的电脑配置如表1。

计算单元	型号及性能	数目	容量
CPU	Intel(R) Xeon(R) Platinum 8369B CPU @ 2.90GHz	128	(RAM 容量) 128.0GB
GPU	NVIDIA GeForce RTX 3090 算力: 7.0	1	24.0 GB

表 1: Configurations of the Computer Executing Experiments

2. 相关工作

2.1. GAN

GAN (生成对抗网络) 是一种深度学习模型, 主要用于生成数据。它由生成器和判别器两部分组成。生成器负责生成尽可能真实的数据, 而判别器的任务是区分生成的数据和真实数据。这两部分在训练过程中相互竞争, 生成器不断学习如何更好地模仿真实数据, 判别器则学习如何更准确地识别生成的数据。二者的相互作用能够生成高度逼真的图像。

GAN 的目标函数如下:

$$\min_G \max_D V(D, G) = E_{x \sim P_{data}(x)} [\log D(x)] + E_{z \sim p_z(z)} [\log(1 - D(G(z)))] \quad (1)$$

此处, $V(D, G)$ 相当于真实样本和生成样本的差异程度, $\max_D V(D, G)$ 意为固定生成器 G , 尽可能使判别器 D 能最大程度判别出样本来自于真实数据还是生成数据。随后 $\min_G V(D, G)$ 意为固定判别器 D , 尽可能使生成器 G 最小化真实样本与生成样本的差异。在上述 $\min$ 与 $\max$ 的博弈对抗中, 在理想情况下, 样本生成分布会收敛到真实分布。

在换脸实验中, 通常需要生成与目标面部结构相匹配的面部特征。GAN 模型, 尤其是其生成器部分, 可以通过训练学会捕捉人脸的关键特征, 如眼睛、鼻子、嘴巴等的形状和位置, 然后将这些特征应用于目标面部, 实现高质量的换脸效果。

2.2. VAE

VAE (变分自编码器) 是另一种深度学习模型, 用于生成和编码数据。VAE 主要由编码器和解码器两部分组成。编码器的任务是将输入数据 (如图像) 转换为一个较小的、压缩的表示形式, 通常称为“潜在空间” (latent space)。解码器则尝试从这个潜在空间重构原始数据。VAE 强调潜在空间的结构和连续性, 这种特性使它特别适用于那些需要平滑、连续变化的应

用，例如图像的平滑过渡。

VAE 的目标函数如下：

$$\max_x L = \sum_x \log \int_z P(z)P(x|z)dz \quad (2)$$

其中 x 表示从真实图片数据中随机抽取的图片，实际上最大化 L 相当于最大化每张真实图片出现的概率，因此上式可等价于 $\max_{each x} \log P(x)$ 。

在进行换脸实验中，VAE 可以学习人脸数据的潜在表示，从而在潜在空间中捕捉面部特征的关键方面。这可以用于生成具有特定属性的新面部图像，或者修改现有图像的特定特征。例如，可以通过在潜在空间中沿着某个方向移动来改变图像中人物的表情或年龄。

2.3. 基于生成模型的换脸模型

为生成特定类别的图片，将生成模型的概率改为条件概率，找到换脸源和换脸目标在潜在空间中的位置 (encode)，向换脸目标中注入换脸源的条件信息，进行重建 (decode) 得到换脸结果。

3. Simswap 架构

3.1. 整体框架




图 1: Simswap 架构 [1]

SimSwap 的结构 (图1) 主要分为生成器 Generator 部分 (下面简称 NetG) 和判别器 Discriminator 部分 (下面简称 Net D)，属于 cGAN-based 生成模型。

但与一般 cGAN 不同的是，SimSwap 并不直接将来源人脸作为条件，而是通过预先训练好的 ID 提取器 [4] 中提取 ID 向量。再通过一系列类似于 ResNet (Resnet) 的区块来注入 ID 向量，这些区块被称为 ID Injection Module(IIM)，在这些区块中，潜向量会被重新投射，并通过 AdaIN[6] 反复注入。这样的设计可以实现关键特征检测和专用修改。

Generator 部分采用了 cVAE 的结构，但在 encoder 和 decoder 之间的 bottleneck 部分 (IIM) 提取换脸源的特征信息并注入到换脸目标的特征信息中。最终的 loss 函数基于生成的换脸结果的特征信息和 Encoder 提取的换脸源的特征信息构建。

Discriminator 部分直接使用了其他模型 (EfficientNet_Lite) 的训练结果。




图 2: *train loss in 100000 epoch*

3.2. 特点

Simswap 基于 DeepFakes 进行了两点改进，改进思路为 encoder 提取的特征中身份信息 and 属性信息是高度耦合的，很难把它们分开，所以引入身份信息修改特征，并使用训练损失来让网络自己学习的哪部分应该改，哪部分应该保持不变。

- 使用 ID Injection Module(IIM) 注入 ID 信息至解码器。通过嵌入源人脸的身份信息对目标人脸的特征进行修改，以此消除身份信息和 decoder 权重之间的相关性，提高各种身份的泛化性。
- 使用 Weak Feature Matching Loss，避免直接注入身份特征导致与属性相关的新跟那个下降，保留目标人脸的属性。

4. Simswap 实验评测

4.1. 参数设置

笔者在 VGG224[2] 与课程整合的数据集上进行 2 组复现，分别是基于原模型 79999 轮训练结果与从 0 开始。两者均训练 1000000 轮，并采用原模型的参数设置。学习率 = 0.0004, batchsize=4/8, lambda_feat=10, lambda_id=30, lambda_reconstruction=10。

4.2. 训练结果

训练前 100000 轮的 NetG loss 变化如图2

训练时采样 8 张具有人脸，将它们同时作为源图像和目标图像构建源-目标人脸的交换结果，发现 Simswapi 模型能保留面部属性（表情、目光、姿势和光照），改变图片的身份。在训练 1000000 后得到的原始模型训练结果见图5a。

4.3. 测试结果

在测试集 [3] 上的表现样例见图6。

笔者使用 cos distance 量化换脸效果, cos distance 的计算方式如式3, source_id 与 result_id 由 Arcface[4] 模型处理对齐后的提供人物特征的图片与换脸图片得到。

$$\text{Cosine Distance}(src_id, res_id) = 1 - \frac{src_id \cdot res_id}{\|src_id\|_2 \times \|res_id\|_2} \quad (3)$$

交换 source_image 与 target_image 后求得原模型在测试集上平均 cosine_distance 为 **0.18**。

5. Simswap 消融实验

笔者修改了 modelfs_network_fix.py 和 modelprojected_model.py 部分以实现消融实验。受时间与资源限制, 设置 batchsize 为 8 进行了 100000 轮训练以粗略观察消融实验的效果。

5.1. 针对 Net G

SimSwap 使用的 Net G 采用 cVAE 的结构, 分为 encoder、IIM、decoder 三个部分。笔者分别对三个部分进行消融实验, 以检验各个部分的功能。




图 3: NetG ablation experiment train

5.1.1. encoder 消融

原模型使用 3 个卷积层作为 encoder, 消融 encoder 使用双三次插值 (BICUBIC) 缩放图片为 encoder 后的 (1, 28, 28) 大小, 并将 3 通道转为灰度图后重新复制拼接为彩图输入 IIM。实验结果见图5b

观察发现移除 encoder 部分 (换用缩放) 后, 依然可以看出换脸源到换脸目标特征的迁移 (图5b中第 4 行展示了不同人物眼部与嘴部的特征), 但是像较原模型, 移除 encoder 后图片边缘碎片化严重 (图5b中第 5 列), 且边缘的处理效果不好。

移除 encoder 后的训练损失见图3

相较于原模型, 使用插值缩放直接 encoder 后 Loss G 能够收敛但是 loss 比原模型大, 由于处于训练前期 Loss ID 差异不大, 重建损失与特征匹配损失均上升。

可见有效的 encoder 对模型性能提升的必要性。

5.1.2. IIM 消融

IIM 将源图片的信息加入目标图片中, 移除这一板块, 发现将无法“换脸”, 图片保持原样。效果如图移除 encoder 后的训练损失见图5c

5.1.3. decoder 消融

原模型使用 3 层 bilinear 上采样 + 卷积, 笔者直使用双三次插值 (BICUBIC) 缩放图片, 并选择前 3 通道。效果如图5d

5.2. 针对 loss

原模型使用的 loss 函数如下所示:

$$L = \lambda_{Id}L_{Id} + \lambda_{Recon}L_{Recon} + L_{Adv} + \lambda_{GP}L_{GP} + \lambda_{wFM}L_{wFM} \quad (4)$$

其中, $\lambda_{Id} = 30, \lambda_{Recon} = 10, \lambda_{GP} = 10^{-5}, \lambda_{wFM} = 10$ 分别为为身份损失 (L_ID) 和重构损失 (L_Recon)、对抗损失 (L_adv) 的 Hinge 版本 [5]、梯度惩罚损失 (L_GP) 和弱特征匹配损失 (l_wFM), 这些损失的定义如下:

$$L_{Id} = 1 - \frac{\langle v_R, v_S \rangle}{\|v_R\|_2 \|v_S\|_2} \quad (5)$$

$$L_{Recon} = \|I_R - I_T\|_1 \quad (6)$$

$$L_{Adv_D} = \max\{0, 1 - D(\mathbf{x})\} + \max\{0, 1 + D(G(\mathbf{z}))\} \quad (7)$$

$$L_{Adv_G} = -D(G(\mathbf{z})) \quad (8)$$

$$L_{GP} = (\|\nabla_{\hat{\mathbf{x}}} D(\hat{\mathbf{x}})\|_2 - 1)^2 \quad (9)$$

$$L_{wFM} = \sum_{i=m}^M \frac{1}{N_i} \|D^{(i)}(I_R) - D^{(i)}(I_T)\|_1 \quad (10)$$

其中 $\hat{\mathbf{x}} = \epsilon \mathbf{x} + (1 - \epsilon) \tilde{\mathbf{x}}, \epsilon \sim U[0, 1]$ 与 pix2pixHD 提出的原始特征匹配不同, 由于换脸结果与换脸目标、换脸源均不同, 但希望换脸结果匹配特定身份的目标, Simswap 引入的弱特征匹

配损失只对判别器最后 3 层提取的特征进行了对比。在弱特征匹配损失的定义中， $D^{(i)}$ 表示判别器 D 的第 i 层， N_i 表示 $D^{(i)}$ 中元素的数量， m 是开始计算特征匹配损失的层。通过忽略前几层，弱特征匹配使网络学会保留目标面孔的属性，而不会对详细纹理（可能导致身份对齐）引入约束。

笔者对 loss 进行了 2 种修改，

- 将 L1 范数形式更改为 L2 范数形式
- 将弱特征匹配损失 L_{wFM} 注释掉或改为强特征匹配

5.2.1. 范数形式修改

在重建损失 L_{Recon} 和弱特征匹配损失 L_{wFM} 中，使用 L2 范数进行特征计算。实验结果如图7。

通过观察发现，换用 L2 范数后，损失函数的收敛速度明显变慢。

5.2.2. 弱特征匹配损失修改

本实验中先注释掉弱特征损失进行训练，结果如图4a；再将弱特征损失替换为强特征损失，即计算每层特征损失（共 4 层）求均值，结果如图4b。




图 4: NetG ablation samples

发现：

- 如果我们去除特征匹配损失 (fm loss)，重构损耗就会变大，这意味着生成器可能会产生与源图片无关的信息，而特征匹配损失可以抑制这种现象；
- 注释掉弱特征损失后生成的图像明显不够自然，出现面部扭曲或不协调的现象。虽然模型收敛速度加快，但换脸质量大大下降
- 强特征损失下生成的换脸图像在细节上更为逼真，但训练收敛速度较慢。这可能因为模型更容易受到训练数据中的噪声或不一致性的影响，引起导致训练过程中的不稳定性。

6. 结论

我们对先 Simswap 模型进行了复现。进行了 2 组训练对 Simswap 换脸任务进行研究，一组基于原模型 80000 轮的模型继续训练，一组从由新数据集从头开始训练。在测试集中评测训练模型的换脸效果，得到的 cosine distance 均值为 0.18。

随后我们对 Simswap 使用的 Generator 和损失函数进行了消融实验。我们验证了 Simswap 引入的身份信息注入模块 IIM 的有效性，分析了不同 encoder 与 decoder 对换脸效果的影响。我们对 Simswap 使用的损失函数中的 feat match loss 进行了分析，发现弱特征匹配损失的必要性，且在较短训练次数 (50000 轮) 内弱特征匹配损失的换脸效果不如全特征匹配损失，但是耗时较短。

7. 改进方式

7.1. 引入分类器处理不同身份信息

根据 [7]，在判别器前引入分类器网络 C 来测量数据的类别概率（潜在的身份信息）。实际上，我们可以将身份损失、重构损失和弱特征匹配损失看作是分类器的替代品，因为它们有助于测量输出与目标身份和属性之间的距离。

7.2. ID 信息注入 (IIM)

为了尽量减少 ID 损失，Simswap 在 IIM 中把源图像中的提取的向量直接粘贴给目标 [6]，不会区分脸部、装饰物、背景或其他特征，但不使用 IIM 将导致 decoder 只以重建原始图片为目标。

对此可以参照 [8] 中的 AAD Generator 模块，融合 decoder 与特征注入部分，更圆滑得处理 Id 信息。

7.3. 遮挡物处理

Simswap 模型利用了 Aceface 作为唯一的身份提取器输入身份信息，该模型在预训练过程中忽略同一人物图像中的配饰，从而使得换脸时排除这些非身份相关的元素。

相反，扩散模型在处理这类数据时，可能会受到干扰模式的影响。在一些情况下，即使源面孔中没有配饰，扩散模型也可能错误地在目标面孔上生成配饰。

针对图片的后期修复，可以参照 [8] 提出的 HEAR NET，一个类似 U-Net 的结构，使用启发式方法处理面部遮挡的恢复。


7.4. encoder 改进

使用 DDPM[9] 等扩散模型。DDPM 作为一种概率生成模型，可通过逐步去除噪声来生成高质量图像。在 SimSwap 中应用 DDPM 可使面部特征合成更平滑、更自然，同时保留原始图像的特征。据研究，DDPM 能有效地提高了人脸替换技术的逼真度和可信度，并减少了生成图像中的伪影和失真。此外，DDPM 的应用为处理更复杂的光照和面部表情变化提供了强有力的支持，从而在保持图像质量的同时提高了人脸替换技术的适用性和灵活性。


8. References

- [1] SimSwap: An Efficient Framework For High Fidelity Face Swapping, *R. Chen, X. Chen, B. Ni, Y. Ge*, 2020, Proceedings of the 28th ACM International Conference on Multimedia, <https://arxiv.org/abs/2106.06340>
- [2] VGG224 数据集: <https://drive.google.com/file/d/19pWvdEHS-CEG6tW3PdxdtZ5QEymVjImc/view>
- [3] 测试集: <https://jbox.sjtu.edu.cn/1/y1TyUv>
- [4] ArcFace: Additive Angular Margin Loss for Deep Face Recognition, *Jiankang Deng, Jia Guo, Jing Yang*, 2018
- [5] Large scale GAN training for high fidelity natural image synthesis, *Brock, Andrew and Donahue, Jeff and Simonyan, Karen*
- [6] Arbitrary style transfer in real-time with adaptive instance normalization, *Huang, Xun and Belongie, Serge*, 2017
- [7] CVAE-GAN: fine-grained image generation through asymmetric training, *Bao, Jianmin and Chen, Dong and Wen, Fang and Li, Houqiang and Hua, Gang*, 2017
- [8] FaceShifter: Towards High Fidelity And Occlusion Aware Face Swapping, *Lingzhi Li, Jianmin Bao, Hao Yang, Dong Chen, Fang Wen*, CVPR 2020, <https://arxiv.org/abs/1912.13457>
- [9] Denoising Diffusion Probabilistic Models, *Jonathan Ho, Ajay Jain, Pieter Abbeel*, NeurIPS 2020

A. train sample



(a) origin sample



(b) without encoder



(c) without IIM



(d) without decoder

图 5: *NetG* ablation samples

B. test sample

C. ablation sample



(a) Image a



(b) b to a



(c) Image b



(d) a to b

图 6: *test_example*




图 7: *ablation on L2 loss*