

n -gram 语言模型

王瑞 & 上海交大 NLP 课程组

2023 年秋

从一个简单的统计模型： n -gram 语言模型开始，了解自然语言处理的基本模式。

- ▶ 数据预处理与标注
- ▶ 语言模型
- ▶ n -gram 语言模型
- ▶ 评估
- ▶ 平滑算法
- ▶ 语言模型的应用

统计方法的成功使用推动了语料库语言学的发展，大规模语料库的出现为自然语言统计处理方法的实现提供了可能。

如何构建大规模语料库？

- ▶ 开放域：互联网数据、官方公布数据
- ▶ 封闭域：领域内部数据、in-house 数据

维基百科

自由的百科全书

首页

分类索引

特色内容

新闻动态

最近更新

随机条目

资助维基百科

帮助

帮助

维基社群

方针与指引

没有登录讨论贡献创建账户登录

条目

讨论

大陆简体 ▾

阅读

编辑

查看历史

搜索维基百科

中文维基百科Facebook粉丝专页已正式上线，邀请大家一同关注。

[关闭]

机器翻译

[编辑]

维基百科，自由的百科全书

提示：此条目的主题不是**电脑辅助翻译**。

机器翻译（英语：Machine Translation，经常简写为MT，简称机译或机翻）属于**计算语言学**的范畴，其研究借由**计算机程序**将文字或演说从一种**自然语言翻译**成另一种自然语言。简单来说，机器翻译是通过将一个自然语言的字辞取代成另一个自然语言的字辞。借由使用**语料库**的技术，可达成更加复杂的自动翻译，包含可更佳的处理不同的**文法结构**、**辞汇辨识**、**惯用语**的对应等。

目前的机器翻译软件通常可允许针对特定领域或是专业领域（例如**天气预报**

翻译

文A

种类

法律 · 文学 · 圣经 · 古兰经 · 佛经 ·

获取电影评论的方法

- 1. 确定所需的数据来自于哪个网站：比如豆瓣
- 2. 确定爬取网站的哪个部分：评论部分

豆瓣电影

搜索电影、电视剧、综艺、艺人

2020年度电影榜单

影评人精选

选电影

电视剧

排行榜

分类

影评

2020年度榜单

2020电影首预告

肖申克的救赎 The Shawshank Redemption (1994)

导演: 弗兰克·德拉邦特

编剧: 弗兰克·德拉邦特 / 斯蒂芬·金

主演: 蒂姆·罗宾斯 / 摩根·弗里曼 / 詹姆斯·克伦威尔 / 詹姆斯·希利 / 詹姆斯·惠特摩 / 彼得·斯特曼 / 戴安娜·斯卡尔维德 / 布鲁斯·坎贝尔 / 乔·古茨 / 迈克尔·塞拉 / 约翰·霍伊特 / 利亚姆·坎宁安 / 吉姆·帕克 / 法兰西·菲利普斯 / 詹姆斯·拉索

类型: 剧情 / 犯罪

制片国家/地区: 美国

语言: 英语

上映日期: 1994-09-10(多伦多电影节) / 1994-10-14(美国)

片长: 142分钟

又名: 肖申克监狱 / 刺激1995(台) / 越狱风暴 / 美国监狱 / 肖申克的救赎

IMDb: tt0111161

豆瓣评分

9.7

★★★★★

2448291人评价

4星 85.6%

5星 13.1%

3星 1.2%

2星 0.1%

1星 0.1%

好于 90% 剧情片

好于 90% 犯罪片

在哪儿看这部电影

腾讯视频

爱奇艺

优酷

腾讯

哔哩哔哩

VIP会员观看

VIP会员观看

VIP会员观看

VIP会员观看

VIP会员观看

想看

看过

评价: ☆☆☆☆

写影评

写短评

分享到

推荐

肖申克的救赎的剧情简介 ·····

一场谋杀使银行家安迪（蒂姆·罗宾斯 Tim Robbins 饰）蒙冤入狱，谋杀妻子及其情人的指控将他终生监禁。在狱中，安迪以自己的智慧和坚韧，赢得了狱友们的尊重和信任。他利用自己的金融知识，帮助狱友们处理各种财务问题，甚至帮助他们逃狱。在漫长的岁月里，安迪始终保持着自己的尊严和信念，最终在狱友的帮助下，成功逃狱，重获自由。

自然语言处理

n-gram 语言模型


王瑞 & 上海交大 NLP 课程组

4 / 60

网页爬虫

网络爬虫（英语：web crawler），也叫网络蜘蛛（spider），是一种用来自动浏览万维网的网络机器人。

讲解实例：Scrapy



爬取数据需要遵守相关网站的协议，以豆瓣为例：

User-agent:

Disallow: /subject_search

Disallow: /amazon_search

Disallow: /search

Disallow: /group/search

Disallow: /event/search

Disallow: /celebrities/search

Disallow: /location/drama/search

Disallow: /forum/

Disallow: /new_subject

Disallow: /service/iframe


数据清理

- ▶ 1. 噪声处理：比如爬取的文本有其他语言的评论，可以用langdetect (讲解例子) 处理。
- ▶ 2. 繁体字转换：抓取的中文文本中可能存在一些繁体字，可以用OpenCC (讲解例子) 等开源工具包完成。
- ▶ 3. 删除过短的评论：对于英文评论，可以直接用空格统计评论文本的词汇数目。对于中文文本，可以分词后统计词汇数目。
- ▶ 4. 标签对应：不同网站上提供的标签类别不尽相同，而类别数目与希望使用的分类器也会有所差异，因此需要进行标签或者类别对应。比如：网站抓取的评分是 1-5，而情感分类只需要褒贬 2 类。

封闭域例子：机器翻译数据获取

由于机器翻译一般应用于特定的领域，直接从互联网获取的语料往往不能满足需求，机器翻译的训练需要：

- ▶ 平行语料：用来训练翻译模型
- ▶ 单语语料：用来训练语言模型



平行语料一般来自于专业的机器翻译测评网站或者官方发布机构，使用和下载需要遵守相关网站的协议：

- ▶ WMT (讲解例子)：世界机器翻译大会
- ▶ UN (讲解例子)：联合国官方语料

单语语料一般来源更广泛：

- ▶ News crawl: Large corpora of crawled news, collected since 2007
- ▶ Wiki dumps: Monolingual text wikipedia, extracted using WikiExtractor

- ▶ 词条化 (tokenization)
- ▶ 去停用词 (stop words)
- ▶ 文本归一化

词条化 (Tokenization) 是为了后续语言处理任务，而对连续的字符串序列进行语言处理单元的划界和分类的过程。

- ▶ 英语/屈折语：tokenization
- ▶ 汉语/黏着语：汉语分词/黏着语分割

汉语自动分词

中文句示例

- ▶ 特朗普在白宫会见安倍晋三。
- ▶ 特朗普/在/白宫/会见/安倍晋三/。
- ▶ 用词位标记的分词结果：特/B (Begin) 朗/M (Middle) 普/E (End) 在/S (单独成词) 白/B 宫/E 会/B 见/E 安/B 倍/M 晋/M 三/E 。/S

讲解例子: jieba 分词

Tokenization

英文句示例

- ▶ I'll see Prof. Zhang home after the concert.
- ▶ I /will /see /Prof. /Zhang /home /after /the /concert /.
- ▶ 讲解例子: prepare.sh

停用词，主要指功能词，通常指在各类文档中出现频繁，附带极少文本信息的助词、介词、连词、语气词等高频词。

- ▶ 英文：the, is, at, which, on 等
- ▶ 中文：“的”、“了”，“是” 等

文本归一化 的目标是转换训练文本，使得它变成纯语言的形式，同时移除很多和语言完全不相关的部分。典型的文本归一化包括：

- ▶ **标点的移除：**

- ▶ +@()!,' +

- ▶ **日期，货币，数字的归一化：**

- ▶ 10/4/1998 $\Rightarrow$ 1998 年 10 月 4 日 $\Rightarrow$ 一九九八年十月四日
 - ▶ \$12.50 $\Rightarrow$ 12.5 美元 $\Rightarrow$ 十二点五美元
 - ▶ 3.67% $\Rightarrow$ 百分之 3.67 $\Rightarrow$ 百分之三点六七

- ▶ **缩写词的归一化：**

- ▶ CNN $\Rightarrow$ C. N. N.


从一个简单的统计模型： n -gram 语言模型开始，了解自然语言处理的基本模式。

- ▶ 数据预处理与标注
- ▶ 语言模型
- ▶ n -gram 语言模型
- ▶ 评估
- ▶ 平滑算法
- ▶ 语言模型的应用

基于大规模语料库和统计方法，语言模型可以


- ▶ 发现语言使用的普遍规律：词频/词组频率统计
- ▶ 进行机器学习、自动获取语言知识
- ▶ 对未知语言现象进行推测率：在机器翻译/语音识别中预测下一个词出现的概率

有限状态机



有限状态机（英语：finite-state machine，缩写：FSM）又称有限状态自动机（英语：finite-state automation，缩写：FSA），简称状态机，是表示有限个状态以及在这些状态之间的转移和动作等行为的数学计算模型。

简单的语法



- ▶ 一个语法网络是一个**加权有限状态机 WFSM**
- ▶ 语法包括词之间的回环，替代，以及重复等。
- ▶ 对那些经常观测到的路径，可以在对应弧 (arcs) 上赋予一个较高分数的权重概率。

统计语言模型

语法网络的使用有很多限制

- ▶ 很难手工去生成大量的语法规则
- ▶ 自然口语说话通常情况下是不合语法的

统计语言模型是一个很吸引人的可替代方法

- ▶ 估计过程是完全基于数据驱动的 (no handcraft)

< sent_start > the overall operation ... string < sent_end >
 w_0 w_1 w_2 w_3 ... w_K w_{K+1}

$$P(W) = P(w_1, w_2, \dots, w_K, w_{K+1}) = \prod_{k=1}^{K+1} P(w_k | w_0, \dots, w_{k-1})$$

句子结尾标识的使用允许实现对句子结束的预测。

语言模型的类别

根据语言模型的计算模式，可以分为

- ▶ n -gram 语言模型：基于实例计数的语言模型
- ▶ 神经网络语言模型：参数化语言模型

```
\data\  
ngram 1=6  
ngram 2=7  
  
\1-grams:  
-0.8908555 <unk> 0  
0 <s> -0.22184873  
-0.8908555 </s> 0  
-0.46488678 我 0  
-0.69896996 你 -0.30103  
-0.69896996 他 -0.30103  
  
\2-grams:  
-0.8908555 我 </s>  
-0.50267535 你 </s>  
-0.24850096 他 </s>  
-0.44889864 <s> 我  
-0.37527603 你 我  
-0.56863624 <s> 你  
-0.6575773 <s> 他  
  
\end\  
  
https://blog.csdn.net/asgreek
```

图: n -gram 语言模型




图: 神经网络语言模型

语言模型的类别

不同的语言模型有着各自的优缺点：

- ▶ n -gram 语言模型：建模简单、速度快；但是对于未知词组预测能力低。
- ▶ 神经网络语言模型：对于未知词组预测能力高；但是由于词表规模较大，速度较慢。

从一个简单的统计模型： n -gram 语言模型开始，了解自然语言处理的基本模式。

- ▶ 数据预处理与标注
- ▶ 语言模型
- ▶ n -gram 语言模型
- ▶ 评估
- ▶ 平滑算法
- ▶ 语言模型的应用


n -gram 模型近似地表示了一个在较短历史情况下的条件概率 (up to n)

$$P(w_k | w_1, \dots, w_{k-1}) = P(w_k | w_{k-1}, \dots, w_{k-n+1})$$


给定的一个当前词的概率仅仅依赖于这个词之前的 $n - 1$ 个前继词。通常使用的 n -gram 模型是

- ▶ $n = 1$: unigram
 - ▶ $n = 2$: bigram
 - ▶ $n = 3$: trigram
 - ▶ $n = 4$: 4-gram (quadrigram)
- ▶ $\hat{P}(\omega_\kappa)$
 - ▶ $\hat{P}(\omega_\kappa | \omega_{\kappa-1})$
 - ▶ $\hat{P}(\omega_\kappa | \omega_{\kappa-2}, \omega_{\kappa-1})$
 - ▶ $\hat{P}(\omega_\kappa | \omega_{\kappa-3}, \omega_{\kappa-2}, \omega_{\kappa-1})$


Unigram 语言模型



Bigram 语言模型



Trigram 语言模型



最大似然估计

在统计学中，最大似然估计（英语：Maximum Likelihood Estimation，简作 MLE），也称极大似然估计，是用来估计一个概率模型的参数的一种方法。

给定一个概率分布，已知其概率密度函数（连续分布）或概率质量函数（离散分布）为 P_θ ，分布参数为 θ ，我们可以从这个分布中抽出一个具有 n 个值的采样集合 $x_1, \dots, x_n$ ，利用 P_θ 计算出其似然函数：

$$\mathcal{L}(\theta \mid x_1, \dots, x_n) = P_\theta(x_1, \dots, x_n).$$

注意：似然函数是变量 θ 和观测数据 $x_1, \dots, x_n$ 的函数

n -gram 语言模型的估计

最大似然准则

数据: 词序列 $W_1^N = [w_1, \dots, w_N]$

模型: 离散概率

$$P(w_k | W_{k-n+1}^{k-1}), \quad w \in \mathcal{V}$$

其中 $\mathcal{V} = \{v_1, \dots, v_M\}$ 是词表

Criterion:

$$\begin{aligned}\mathcal{L}(\theta) &= \frac{1}{K} \sum_{k=1}^K \log P(w_k | W_{k-n+1}^{k-1}) \\ &= \frac{1}{K} \sum_{v \in \mathcal{V}} \sum_{y \in \mathcal{Y}} \sum_{k: w_k=v, y=W_{k-n+1}^{k-1}} \log P(v|y) \\ &= \frac{1}{K} \sum_{v \in \mathcal{V}} \sum_{y \in \mathcal{Y}} C(y, v) \log P(v|y)\end{aligned}$$

其中 $\mathcal{Y}$ 是所有可能的 n -gram 历史的集合, $C(y, v)$ 是训练集中完整 n -gram (y, v) 的数目。

n -gram 语言模型的估计

优化

$$\hat{P}(v|y) = \arg \max_{P(v|y)} \sum_{v \in \mathcal{V}} \sum_{y \in \mathcal{Y}} C(y, v) \log P(v|y), \quad s.t. \sum_{v \in \mathcal{V}} P(v|y) = 1$$

使用拉格朗日乘子，针对参数 $P(v|y)$ 的带约束的优化可以表示为

$$Q(P(v|y)) = C(y, v) \log P(v|y) + \lambda \left(\sum_{v \in \mathcal{V}} P(v|y) - 1 \right), v \in \mathcal{V}$$

分别关于参数 $P(v|y)$ 与 λ 对以上式子求偏导数，并令其等于零：

$$\frac{\partial Q}{\partial P(v|y)} = 0, v \in \mathcal{V} \qquad \frac{\partial Q}{\partial \lambda} = 0$$

n -gram 语言模型的估计

优化

$$\begin{aligned} \frac{C(y, v)}{\hat{P}(v|y)} + \lambda &= 0, v \in \mathcal{V} \\ -\frac{C(y, v)}{\lambda} &= \hat{P}(v|y), v \in \mathcal{V} \end{aligned} \quad \Rightarrow \quad \begin{aligned} \sum_{v \in \mathcal{V}} \hat{P}(v|y) - 1 &= 0 \\ -\frac{\sum_{v \in \mathcal{V}} C(y, v)}{\lambda} &= 1 \\ -\sum_{v \in \mathcal{V}} C(y, v) &= \lambda \end{aligned}$$

因此, 对 $\forall v \in \mathcal{V}$, 有

$$\hat{P}(v|y) = \frac{C(y, v)}{C(y)}$$

其中

$$C(y) = \sum_{v \in \mathcal{V}} C(y, v)$$

n -gram 语言模型的估计

Unigram 示例

Training sentences:

<S> I HAVE A RED CAR <S>
<S> I BUY A NEW CAR <S>
<S> THEY HAVE A NEW BOOK <S>

Vocabulary:

A	BOOK	BUY	CAR	HAVE	I	NEW	RED	THEY
---	------	-----	-----	------	---	-----	-----	------

Unigram 语言模型:

$P(A)$	3/15	$P(BOOK)$	1/15	$P(BUY)$	1/15
$P(CAR)$	2/15	$P(HAVE)$	2/15	$P(THEY)$	2/15

n -gram 语言模型的估计

Bigram 示例

Training sentences:

<S> I HAVE A RED CAR <S>
<S> I BUY A NEW CAR <S>
<S> THEY HAVE A NEW BOOK <S>

Bigram 语言模型:

$P(I < S >)$	2/3	$P(THHEY < S >)$	1/3	$P(NEW A)$	2/3
$P(RED A)$	1/3	$P(A BUY)$	1/1	$P(A HAVE)$	2/2
$P(HAVE I)$	1/2	$P(BUY I)$	1/2	$P(CAR NEW)$	1/2
$P(BOOK NEW)$	1/2	$P(CAR RED)$	1/1	$P(HAVE THEY)$	1/1

从一个简单的统计模型： n -gram 语言模型开始，了解自然语言处理的基本模式。

- ▶ 数据预处理与标注
- ▶ 语言模型
- ▶ n -gram 语言模型
- ▶ 评估
- ▶ 平滑算法
- ▶ 语言模型的应用

信息和熵

信息

- ▶ **信息**: “传达的消息”，它包含了不确定性。
- ▶ **不确定性**: 由事件发生的概率度量，且与之成比例。一个事件越不确定，就需要越多的信息来消除它的不确定性。
- ▶ 离散变量 x 中的信息是:

$$I(x) = -\log_2 P(x)$$

- ▶ **熵**: 整个信源的平均信息就是对整体不确定性的度量, 单位是比特 (bits) 或奈特 (nats)

$$H = \mathbb{E}[-\log_2 P(x)] = - \sum_{x \in X} P(x) \log_2 P(x)$$

$$H = \mathbb{E}[I(x)] = - \int_{-\infty}^{\infty} p(x) \log_e(p(x)) dx$$

- ▶ 熵在编码理论、统计物理、机器学习中都是一个重要的量
- ▶ 熵是随机变量的信息的期望
- ▶ 熵是分布 $p(x)$ 的函数

Q: x 是一个有 8 种可能状态的离散变量, 需要用多少 bits 来传输 x 的状态?

信息和熵

熵



x	a	b	c	d	e	f	g	h
$p(x)$	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{16}$	$\frac{1}{64}$	$\frac{1}{64}$	$\frac{1}{64}$	$\frac{1}{64}$
code	0	10	110	1110	111100	111101	111110	111111

$$\begin{aligned} H[x] &= -\frac{1}{2} \log_2 \frac{1}{2} - \frac{1}{4} \log_2 \frac{1}{4} - \frac{1}{8} \log_2 \frac{1}{8} - \frac{1}{16} \log_2 \frac{1}{16} - \frac{4}{64} \log_2 \frac{1}{64} \\ &= 2 \text{ bits} \end{aligned}$$

$$\begin{aligned} \text{average code length} &= \frac{1}{2} \times 1 + \frac{1}{4} \times 2 + \frac{1}{8} \times 3 + \frac{1}{16} \times 4 + 4 \times \frac{1}{64} \times 6 \\ &= 2 \text{ bits} \end{aligned}$$

信息和熵

熵



- ▶ 条件熵是条件分布 $p(y|x)$ 的熵的期望。

$$\begin{aligned} H[y|x] &= \sum_{x'} P(x) H(y|x = x') \\ &= - \sum_x P(x) \sum_y P(y|x) \ln P(y|x) \end{aligned}$$

$$H[y|x] = - \iint p(y, x) \ln p(y|x) \, dy \, dx$$

- ▶ 联合熵是条件熵和边缘熵之和

$$H[x, y] = H[y|x] + H[x]$$


信息和熵

互信息

互信息是对称的，它是边缘熵和条件熵的差。

$$I[x, y] \equiv - \iint p(x, y) \ln \left(\frac{p(x)p(y)}{p(x, y)} \right) dx dy$$

$$I[x, y] = H[x] - H[x|y] = H[y] - H[y|x]$$



- ▶ KL 距离广泛用于描述两个分布的差异，KL 距离是非对称的

$$\begin{aligned}\text{KL}(p\|q) &= - \int p(x) \ln q(x) dx - \left(- \int p(x) \ln p(x) dx \right) \\ &= - \int p(x) \ln \left\{ \frac{q(x)}{p(x)} \right\} dx\end{aligned}$$

$$\text{KL}(p\|q) \geq 0 \quad \text{KL}(p\|q) \neq \text{KL}(q\|p)$$

- ▶ 互信息和 KL 距离的关系

$$\begin{aligned}I[x, y] &\equiv \text{KL}(p(x, y)\|p(x)p(y)) \\ &= - \iint p(x, y) \ln \left(\frac{p(x)p(y)}{p(x, y)} \right) dx dy\end{aligned}$$

- 交叉熵是两个分布 $q(x)$ 和 $p(x)$ 之间信息的期望

$$H_c(P, Q) = - \sum_x P(x) \log_2 Q(x)$$

$$H_c(p, q) = - \int_x p(x) \ln q(x) dx$$

- 交叉熵是非对称的
- 信息论角度，基于相同事件测度的两个概率分布 p 和 q 的交叉熵是指，当基于一个“非自然”（相对于“真实”分布 p 而言）的概率分布 q 进行编码时，在事件集合中唯一标识一个事件所需要的平均比特数（bit）

如何测量语言模型的质量

交叉熵 – Cross Entropy

语言模型的评价方法：在预留的文本数据集上的预测度

Cross-entropy：在 n -gram 模型 $P(\cdot)$ 和实际的开发文本集合上的实际词分布 $P_{\text{data}}(\cdot)$ 之间的交叉熵被广泛地用作语言模型的评价指标。可以认为它是一个平均对数（底数为 2）似然分数。

$$\begin{aligned} H(P, Q) &= - \sum_{v \in \mathcal{V}} \sum_{y \in \mathcal{Y}} P_{\text{data}}(v|y) \log_2 P(v|y) \\ &\approx - \frac{1}{K} \sum_{v \in \mathcal{V}} \sum_{y \in \mathcal{Y}} C(y, v) \log_2 P(v|y) \\ &\approx - \frac{1}{K} \sum_{k=1}^K \log_2 P(w_k | W_{k-n+1}^{k-1}) = -\mathcal{L}(\theta) \end{aligned}$$

如何测量语言模型的质量

困惑度 – Perplexity

Perplexity 定义如下

$$\begin{aligned}\text{PPL} &= 2^{-\mathcal{L}(\theta)} = 2^{-\frac{1}{K} \sum_{k=1}^K \log_2 P(w_k | W_{k-n+1}^{k-1})} \\&= \left(2^{-\sum_{k=1}^K \log_2 P(w_k | W_{k-n+1}^{k-1})} \right)^{\frac{1}{K}} = \left(\prod_{k=1}^K 2^{-\log_2 P(w_k | W_{k-n+1}^{k-1})} \right)^{\frac{1}{K}} \\&= \left(\prod_{k=1}^K \frac{1}{P(w_k | W_{k-n+1}^{k-1})} \right)^{\frac{1}{K}}\end{aligned}$$

- ▶ Perplexity 是语言模型在数据上的概率值倒数的几何平均
- ▶ 可以被理解或解释成**分支度 branching factor** 讲解例子
- ▶ 越低的 PPL 说明越好的预测能力

Perplexity 示例

电话号码 的例子。假定

- ▶ 所有电话号码都是 6 位数字长度
- ▶ 所有数字都是等概率的以 "33", "74", "76" 开头
- ▶ 所有其他的数字都是等概率的

实验中, 使用 10000 或者 100 个数字串去训练 n -gram 语言模型, 然后使用 1000 数字串去测试。

Language Model	10000		100	
	Train	Test	Train	Test
Equal	11.00	11.00	11.00	11.00
Unigram	10.04	10.01	10.04	10.04
Bigram	7.12	7.13	6.56	∞

Q: 为什么 bigram 模型的 perplexity 测试可能是 ∞ ?

从一个简单的统计模型： n -gram 语言模型开始，了解自然语言处理的基本模式。

- ▶ 数据预处理与标注
- ▶ 语言模型
- ▶ n -gram 语言模型
- ▶ 评估
- ▶ 平滑算法
- ▶ 语言模型的应用

n -gram 语言模型的数据稀疏问题

数据稀疏问题一直存在：大词表情况下的高阶 n -gram。


数据稀疏的相关问题主要有如下：

- ▶ **零概率 (Unseen)** 的 n -grams 将会导致无穷大的分支度 PPL
- ▶ **低频次 (Very low)** 的 n -grams 将会导致不可靠的估计

两种解决方案：

- ▶ **折扣法 (Discounting)**
修正原始 n -gram 的频次，使得概率量重新分布，从通常容易观测到的 n -gram 分布 $\rightarrow$ 频次较低或者根本没有的 n -gram 上
- ▶ **回退及插值 (Backing-off and interpolation)**
回退策略递归地回退到较低阶的 n -gram 上，直到得到一个鲁棒的概率估计

折扣法 (Discounting)



为了把一些概率值重新分布到没有看到过的 n -gram 上，我们需要去减少那些在原本训练文本中的看到过的 n -gram 的频次（打折扣），从而满足概率和为 1 的要求。

$$\hat{P}_{\text{ML}}(w|y) = \frac{C(y, w)}{C(y)} \quad \hat{P}_{\text{Discount}}(w|y) = d(y, w) \frac{C(y, w)}{C(y)}$$

其中 $d(y, w)$ 是一个折扣 (discount) 系数

Good Turing Discounting

基本的想法：将训练数据中出现次数为 $r + 1$ 次的 n -gram 的概率重新分配给出现次数为 r 次的 n -gram。

$$r^* = (r + 1) \frac{N_{r+1}}{N_r} \quad d(r) = \frac{(r + 1)N_{r+1}}{rN_r}$$

其中 N_r 表示 **count of counts**, i.e. 在训练集中出现次数是 r 次的 n -gram 的数量。因而，训练集中所能观测到的 n -grams 的总数是：

$$N = \sum_{r=0}^{\infty} rN_r = \sum_{r=1}^{\infty} rN_r$$

一个 n -gram 的概率可以定义为

$$P(v : C(v) = r) = \frac{r^*}{N}$$

- ▶ 在进行折扣算法之前，需要先对 N_r 做一些调整
- ▶ 分配给未出现过的 n -gram 的概率量是 $\frac{N_1}{N}$

示例

Frequency table: (applying $r^* = (r + 1) \frac{N_{r+1}}{N_r}$)

r	Symbols	N_r	rN_r	$P(x)$
0	C, H	2	0	0
1	A, B, E, I	4	4	4/13
2	D, F, G	3	6	6/13
3	J	1	3	3/13
Total			13	1

r^*	Symbols	N_r	rN_r	$P(x)$
2	C, H	2	4	4/13
3/2	A, B, E, I	4	6	6/13
1	D, F, G	3	3	3/13
1	J	1	0	0
Total			13	1

- ▶ 那些出现 r 次的 n -gram 的概率已被重新分配给那些出现了 $r + 1$ 次的 n -gram。
- ▶ Good turing discounting 通常仅仅应用于低频次的词

Jelinek-Mercer Smoothing (Interpolation)

Good-Turing: 未出现过的 n -grams 被赋予相同的频次

$$\left. \begin{array}{l} C(\text{Be}, \text{Happy}) = 0 \\ C(\text{Be}, \text{ZZZ}) = 0 \end{array} \right\} \Rightarrow P(\text{ZZZ}|\text{Be}) = P(\text{Happy}|\text{Be})$$

这个结果似乎有问题, 因为 $P(\text{Happy}) > P(\text{ZZZ})$

解决方案: 在 unigram 和 bigram 之间插值

$$P^*(w_i|w_{i-1}) = \lambda P(w_i|w_{i-1}) + (1 - \lambda)P(w_i)$$

可以推广到高阶情况

$$P^*(w_i|W_{i-n+1}^{i-1}) = \lambda_n P(w_i|W_{i-n+1}^{i-1}) + (1 - \lambda_n)P(w_i|W_{i-n+2}^{i-1})$$

λ_n 可以在预留出来的开发数据集上学习得到。

Katz's Back-off Model

回退 (Back-off) : 在估计那些训练文本中从没见过或者见过频次很少的 n -gram 的概率时, 使用某些条件下相对较短的历史。

$$P_{\text{bo}}(w_k | W_{k-n+1}^{k-1}) = \begin{cases} d(W_{k-n+1}^k) \frac{C(W_{k-n+1}^k)}{C(W_{k-n+1}^{k-1})} & C(W_{k-n+1}^k) > t \\ \alpha(W_{k-n+1}^{k-1}) P_{\text{bo}}(w_k | W_{k-n+2}^{k-1}) & \text{otherwise} \end{cases}$$

- ▶ t 一般情况下置成零 (仅仅在 n -gram 完全没有出现的时候进行回退)
- ▶ d 和 α 分别是折扣因子 (discounting factor) 和回退权重 (back-off weights)
- ▶ Good-Turing 回退方法经常被作为 d 来使用
- ▶ 选取 α 使得

$$\sum_{w_k}^V P_{\text{bo}}(w_k | W_{k-n+1}^{k-1}) = 1$$

- ▶ 对同一个语言模型中的不同阶数 n -gram 的概率进行插值
- ▶ 对具有相同 n -gram 阶数的不同语言模型进行插值

$$P(w_i | W_{i-n+1}^{i-1}) = \sum_{m=1}^M \lambda_m P_m(w_i | W_{i-n+1}^{i-1})$$

其中 λ_m 可以通过在一个预留的开发集合上通过 MLE 最大似然准则估计得到

- ▶ 对综合来自不同数据源的信息很有用
- ▶ 做语言模型自适应的快速方式

基于类的语言模型 Class-based Language Model

- ▶ Class-based LM 使用参数绑定的方法来得到更加鲁棒的 n -gram 概率估计
- ▶ 将 n -gram 的历史信息归成不同的类别

$$P(w_i | W_{i-n+1}^{i-1}) = P(w_i | G_i) P(G_i | G_{i-n+1}^{i-1})$$

其中 $G(w)$ 表示映射词 w_i 为它的相关类或组的函数。

I (noun) buy (verb) a (article) book (noun).

He (noun) sold (verb) a (article) car (noun).

- ▶ 归类或分组工作一般在词层面来实现
- ▶ Class-based LMs 往往和 word-based LMs 进行插值来得到进一步的性能改进

从一个简单的统计模型： n -gram 语言模型开始，了解自然语言处理的基本模式。

- ▶ 数据预处理与标注
- ▶ 语言模型
- ▶ n -gram 语言模型
- ▶ 评估
- ▶ 平滑算法
- ▶ 语言模型的应用

常用的 n -gram 训练工具有 SRILM、IRSTLM、BerkeleyLM 和 KenLM 等。这几种工具所用的算法思想基本一致，只是在实现细节上有所不同。

- ▶ SRILM (讲解例子)
- ▶ KenLM(讲解例子)

语言模型在语音识别中的应用

将语言模型集成至语音识别系统中通常有 2 种策略：**First-Pass** 与 **Second-Pass**。


- ▶ **First-Pass**：在识别解码过程中引入语言模型打分，作为选择最优解码路径的依据之一。
 - ▶ 该策略能够及时对不合自然语言规则的解码路径进行剪枝，但若语言模型过大，将显著影响解码效率。
- ▶ **Second-Pass**：在解码得到若干可能结果序列后，使用语言模型对每个序列重打分 (rescore)，并选择得分最高的序列作为最终识别结果。
 - ▶ 该策略对识别效率的影响更为可控，可以集成更大的语言模型，但系统识别性能严重依赖于初始结果序列集合的质量。

实际系统中，通常同时使用两种策略（即两趟解码）：将一个小的语言模型集成至解码过程中帮助剪枝，并使用另一个更大的语言模型进行重打分。

加权有限状态转录机 (WFST)

加权有限状态转录机 (Weighted Finite-State Transducer, WFST) 是语音识别构图的一种主流方法。它由一组状态 (State) 和状态间的有向跳转 (Transition) 构成, 每个跳转上包含 3 种信息: 输入标签, 输出标签和权重。

有关 WFST 的详细介绍, 可以参考 Mohri, et al. *Speech Recognition With Weighted Finite-State Transducers*.



语言模型在机器翻译中的应用

n -gram 语言模型是统计机器翻译的核心成分，与翻译模型、调序模型一起联合解码，生成最终的翻译结果。

