

3.1 词向量

陈 露

上海交通大学计算机科学与工程系
2023年秋季学期

- ▶ 词的表示
 - ▶ 单热点词向量
 - ▶ 分布式词向量
- ▶ 两个经典的词向量模型
 - ▶ CBOW模型
 - ▶ Skip-gram模型
- ▶ 词向量的性质
- ▶ 动态词向量

- ▶ 词的表示
 - ▶ 单热点词向量
 - ▶ 分布式词向量
- ▶ 两个经典的词向量模型
 - ▶ CBOW模型
 - ▶ Skip-gram模型
- ▶ 词向量的性质
- ▶ 动态词向量

狗

dog



狗：哺乳动物，种类很多，听觉嗅觉都很敏锐，善于看守门户。

这些表示不适合机器学习模型/神经网络直接使用

词的向量表示方式

例句：我爱自然语言处理

我	爱	自	然	语	言	处	理
$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}$

我	爱	自然语言处理
$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$


没法表达词与词之间的远近亲疏

词的向量表示方式

例句：我爱自然语言处理

我 爱 自然语言处理

我	爱	自然语言处理
0.94	0.25	0.54
0.45	0.35	0.20
0.25	0.54	0.93
0.02	0.19	0.13
0.30	0.93	0.37



词的连续向量表示为什么又称作“分布式表达”？

单热点向量的表示方式中，每个词对应于特定的维度，其由且仅由这一维度表示，因此也被称为“局部语义表达”或“非分布式表达”。与之相对的，采用连续稠密向量的表示方式，词的语义分散在不同的维度中表达，因此被称为“分布式表达”。

- ▶ 词的表示
 - ▶ 单热点词向量
 - ▶ 分布式词向量
- ▶ 两个经典的词向量模型
 - ▶ CBOW模型
 - ▶ Skip-gram模型
- ▶ 词向量的性质
- ▶ 动态词向量

You shall know a word by the company it keeps.




约翰·鲁伯特·弗斯
英国语言学家
伦敦学派创始人

- ▶ 我**看见**一只**小猫**快速跑进了**教室**
- ▶ 我**发现**一只**小狗**快速跑进了**屋里**

两种不同的词向量模型


小猫



用上下文预测当前词 (CBOW模型)

我 看见 一只 快速 跑进了 教室


小猫



用当前词预测上下文 (Skip-gram模型)

我 看见 一只 快速 跑进了 教室

小猫



用上下文预测当前词 (CBOW模型)

我 看见 一只 快速 跑进了 教室

小猫




用当前词预测上下文 (Skip-gram模型)

我 看见 一只 快速 跑进了 教室

CBOW模型：考虑只有一个上文词的特殊情况

小猫



用上下文预测当前词 (CBOW模型)

~~我 看见 一只~~ ■ ~~快速 跑进了 教室~~


小猫



用当前词预测上下文 (Skip-gram模型)


我 看见 一只 快速 跑进了 教室

CBOW模型：考虑只有一个上文词的特殊情况



- ▶ 输入 $\mathbf{x}$ 为独热向量 $\mathbf{x} = [x_1, x_2, \dots, x_k, \dots, x_N] = [0, 0, \dots, 1, \dots, 0]$
- ▶ 输出 $\mathbf{y}$ 为概率分布向量，即 $\sum_{t=1}^N y_t = 1$


CBOW模型：考虑只有一个上文词的特殊情况



- ▶ $\mathbf{U}$ 和 $\mathbf{V}$ 为两个参数矩阵


$$\mathbf{U} = \begin{bmatrix} \mathbf{u}_1 \\ \mathbf{u}_2 \\ \dots \\ \mathbf{u}_k \\ \dots \\ \mathbf{u}_N \end{bmatrix} \quad \mathbf{V} = \begin{bmatrix} \mathbf{v}_1 \\ \mathbf{v}_2 \\ \dots \\ \mathbf{v}_i \\ \dots \\ \mathbf{v}_N \end{bmatrix}$$

CBOW模型：考虑只有一个上文词的特殊情况



- ▶ 隐层向量 $\mathbf{h} = \mathbf{U}^T \mathbf{x}$
- ▶ 概率归一化之前的输出向量 $\mathbf{o} = \mathbf{V} \mathbf{h}$
- ▶ 概率归一化的概率分布向量 $y_j = \frac{\exp(o_j)}{\sum_{t=1}^N \exp(o_t)}$

CBOW模型：考虑只有一个上文词的特殊情况




► 交叉熵损失函数 $E = -\log y_j$

► 梯度下降更新参数

$$\mathbf{v}_i = \mathbf{v}_i - \eta \frac{\partial E}{\partial \mathbf{v}_i}$$

$$\mathbf{u}_k = \mathbf{u}_k - \eta \frac{\partial E}{\partial \mathbf{u}_k}$$

CBOW模型：考虑只有一个上文词的特殊情况



$$\frac{\partial E}{\partial \mathbf{v}_i} = ?$$


$$E = -\log y_j$$

$$= -\log \frac{\exp(o_j)}{\sum_{t=1}^N \exp(o_t)}$$

$$= -o_j + \log \sum_{t=1}^N \exp(o_t)$$

$$o_t = \mathbf{v}_t \mathbf{h}$$

CBOW模型：考虑只有一个上文词的特殊情况



$$\frac{\partial E}{\partial \mathbf{v}_i} = \frac{\partial E}{\partial o_i} \frac{\partial o_i}{\partial \mathbf{v}_i} = e_i \mathbf{h}^T$$

$$\mathbf{v}_i = \mathbf{v}_i - \eta \frac{\partial E}{\partial \mathbf{v}_i} = \mathbf{v}_i - \eta e_i \mathbf{h}^T$$


$$E = -o_j + \log \sum_{t=1}^N \exp(o_t)$$

$$\frac{\partial E}{\partial o_i} = -1(i = j) + y_i \longrightarrow e_i$$

$$o_i = \mathbf{v}_i \mathbf{h}$$

$$\frac{\partial o_i}{\partial \mathbf{v}_i} = \mathbf{h}^T$$

CBOW模型：考虑只有一个上文词的特殊情况



$$\frac{\partial E}{\partial \mathbf{u}_k} = \frac{\partial E}{\partial \mathbf{h}^T}$$

$$\frac{\partial E}{\partial \mathbf{h}} = \sum_{i=1}^N \frac{\partial E}{\partial o_i} \frac{\partial o_i}{\partial \mathbf{h}} = \sum_{i=1}^N e_i \mathbf{v}_i^T$$


$$\mathbf{u}_k = \mathbf{u}_k - \eta \frac{\partial E}{\partial \mathbf{u}_k} = \mathbf{u}_k - \eta \sum_{i=1}^N e_i \mathbf{v}_i$$

$$E = -o_j + \log \sum_{t=1}^N \exp(o_t)$$

$$\frac{\partial E}{\partial o_i} = -1(i = j) + y_i \longrightarrow e_i$$

$$o_i = \mathbf{v}_i \mathbf{h} \quad \frac{\partial o_i}{\partial \mathbf{h}} = \mathbf{v}_i^T$$

CBOW模型：考虑只有一个上文词的特殊情况



$$\mathbf{u}_k = \mathbf{u}_k - \eta \frac{\partial E}{\partial \mathbf{u}_k} = \mathbf{u}_k - \eta \sum_{i=1}^N e_i \mathbf{v}_i$$


$\mathbf{eV}$

$$\frac{\partial E}{\partial o_i} = -1(i = j) + y_i$$


e_i

$$\mathbf{e} = [e_1, e_2, \dots, e_N]$$

CBOW模型：考虑更多的上下文




CBOW模型：考虑更多的上下文



$$v_i = v_i - \eta \frac{\partial E}{\partial v_i} = v_i - \eta e_i h^T$$

形式不变

CBOW模型：考虑更多的上下文



$$\mathbf{u}_k = \mathbf{u}_k - \eta \frac{\partial E}{\partial \mathbf{u}_k} = \mathbf{u}_k - \eta \mathbf{V}^T \mathbf{e}$$



$$\mathbf{u}_{k_i} = \mathbf{u}_{k_i} - \eta \frac{\partial E}{\partial \mathbf{u}_{k_i}} = \mathbf{u}_{k_i} - \frac{\eta \mathbf{V}^T \mathbf{e}}{C}$$

Skip-gram模型


小猫



用上下文预测当前词 (CBOW模型)

我 看见 一只 快速 跑进了 教室


小猫



用当前词预测上下文 (Skip-gram模型)

我 看见 一只 快速 跑进了 教室

Skip-gram模型



$$\begin{aligned} E &= -\log P(w_{j_1}, w_{j_2}, \dots, w_{j_c} | w_k) \\ &= -\log \prod_{i=1}^c P(w_{j_i} | w_k) = -\sum_{i=1}^c \log P(w_{j_i} | w_k) \end{aligned}$$

<https://arxiv.org/pdf/1411.2738.pdf>

Efficient Estimation of Word Representations in Vector Space

Tomas Mikolov

Google Inc., Mountain View, CA
tmikolov@google.com

Kai Chen


Google Inc., Mountain View, CA
kaichen@google.com

Greg Corrado

Google Inc., Mountain View, CA
gcorrado@google.com

Jeffrey Dean

Google Inc., Mountain View, CA
jeff@google.com



Tomas Mikolov

Distributed Representations of Words and Phrases and their Compositionality

Tomas Mikolov

Google Inc.
Mountain View
mikolov@google.com

Ilya Sutskever

Google Inc.
Mountain View
ilyasu@google.com

Kai Chen

Google Inc.
Mountain View
kai@google.com

Greg Corrado

Google Inc.
Mountain View
gcorrado@google.com

Jeffrey Dean

Google Inc.
Mountain View
jeff@google.com

词向量模型的优化


- ▶ 由于实际应用中涉及的词表很大，而softmax中又涉及大量无法约简的指数运算，因此输出端的计算开销非常大
- ▶ 为了实现高效的训练，有两种降低输出维度的方法
 - ▶ 分层柔性最大化 (hierarchical softmax)
 - ▶ 负采样 (negative sampling)
- ▶ 这两种方法的思想都是将一个多分类任务转化为多个二分类任务

词向量模型的优化: Hierarchical Softmax



- Hierarchical Softmax

- 将多分类问题转换为多个二分类问题，组成一棵二叉分类树

- 以三分类问题为例



词向量模型的优化: Hierarchical Softmax



用二进制串表示二叉分类树上的分类路径，用0表示走左分支，1表示走右分支

$$\hat{P}(y_1) = \text{softmax}_1(y)$$

$$\hat{P}(y_2) = \text{softmax}_2(y)$$

$$\hat{P}(y_3) = \text{softmax}_3(y)$$

$$\tilde{P}(y_1) = \tilde{P}(00)$$

$$= (1 - \sigma(y_3))(1 - \sigma(y_2))$$

$$\tilde{P}(y_2) = \tilde{P}(01)$$

$$= (1 - \sigma(y_3))\sigma(y_2)$$

$$\tilde{P}(y_3) = \tilde{P}(1)$$

$$= \sigma(y_3)$$

词向量模型的优化: Hierarchical Softmax


- ▶ 任意构造的二叉树不一定能达到最优的效率
- ▶ 效率上最优的二叉树应满足平均最少的分类次数，即平均最短的二进制路径长度
- ▶ 哈夫曼树在通信中被用于设计信源已知情况下的最优信道编码，基于哈夫曼树的哈夫曼编码具有最短的平均码长
- ▶ 类似的，二叉哈夫曼树就是最优的二叉分类树

词向量模型的优化: Hierarchical Softmax

- ▶ 任意构造的二叉树不一定能达到最优的效率
- ▶ 效率上最优的二叉树应满足平均最少的分类次数，即平均最短的二进制路径长度
- ▶ 哈夫曼树在通信中被用于设计信源已知情况下的最优信道编码，基于哈夫曼树的哈夫曼编码具有最短的平均码长
- ▶ 类似的，二叉哈夫曼树就是最优的二叉分类树


词向量模型的优化: Hierarchical Softmax

- ▶ 哈夫曼树可以利用贪心法，不断地合并权重最小的子树得到
- ▶ 以五分类情况为例
- ▶ 假设5个类别的样本数之比为1:1:2:5:3




词向量模型的优化: Hierarchical Softmax

- ▶ 哈夫曼树可以利用贪心法，不断地合并权重最小的子树得到
- ▶ 以五分类情况为例
- ▶ 假设5个类别的样本数之比为1:1:2:5:3




词向量模型的优化: Hierarchical Softmax

- ▶ 哈夫曼树可以利用贪心法，不断地合并权重最小的子树得到
- ▶ 以五分类情况为例
- ▶ 假设5个类别的样本数之比为1:1:2:5:3




词向量模型的优化: Hierarchical Softmax

- ▶ 哈夫曼树可以利用贪心法，不断地合并权重最小的子树得到
- ▶ 以五分类情况为例
- ▶ 假设5个类别的样本数之比为1:1:2:5:3



词向量模型的优化: Hierarchical Softmax


- ▶ 假设5个类别的样本数之比为1:1:2:5:3



此时的平均分类次数，也即该树叶子节点的加权路径长度为：

$$\frac{1}{12}(5 \times 1 + 3 \times 2 + 1 \times 4 + 1 \times 4 + 2 \times 3) \approx 2.08$$

词向量模型的优化: Negative Sampling



大量的计算来自于输出层里的归一化：
$$y_j = \frac{\exp(o_j)}{\sum_{t=1}^N \exp(o_t)}$$

但是实际上我们并不需要真正去计算上面这个概率，我们只需要模型能够在正确单词上的输出尽可能大，错误单词上的输出尽可能小

词向量模型的优化: Negative Sampling

我们把优化函数重新设计成这样:


1. 最大化正确单词上的输出
2. 定义一个噪声分布, 每次最大化上面那个目标的同时, 按照这个噪声分布去词汇表里随机取几个词, 然后最小化这些单词上的输出。

不需要归一化, 甚至不需要算每个单词的输出概率!

$$E = \boxed{\log \sigma(o_j)} + \boxed{\sum_{i=1}^K \mathbb{E}_{i \sim P_{noise}(i)} [\log(-\sigma(o_i))]}$$

最大化正确单词上的输出

从噪声分布 P_{noise} 中采样 K 个样本,
并最小化这些噪声单词上的输出




$$\sigma(y) = \frac{e^y}{e^y + 1} = \frac{1}{1 + e^{-y}}$$

词向量模型的优化：Negative Sampling

- ▶ 噪声分布 P_{noise} 采用如下分布：

$$P(w_i|\mathcal{C}) = \frac{\alpha_i^{\frac{3}{4}}}{\sum_j \alpha_j^{\frac{3}{4}}}$$


- ▶ 其中 α_i 表示词 i 在语料库中出现频率
- ▶ 采用小于1的幂形式可以适当增加罕有助于改善训练的词向量的性能



$f(x) = x^{\frac{3}{4}}$ 函数图像

- ▶ 词的表示
 - ▶ 单热点词向量
 - ▶ 分布式词向量
- ▶ 两个经典的词向量模型
 - ▶ CBOW模型
 - ▶ Skip-gram模型
- ▶ 词向量的性质
- ▶ 动态词向量

聚类和平移特性



$$\mathbf{u}(\text{queen}) - \mathbf{u}(\text{woman}) \approx \mathbf{u}(\text{king}) - \mathbf{u}(\text{man})$$
$$\mathbf{u}(\text{France}) - \mathbf{u}(\text{Paris}) \approx \mathbf{u}(\text{England}) - \mathbf{u}(\text{London})$$

...

- ▶ 词的表示
 - ▶ 单热点词向量
 - ▶ 分布式词向量
- ▶ 两个经典的词向量模型
 - ▶ CBOW模型
 - ▶ Skip-gram模型
- ▶ 词向量的性质
- ▶ 动态词向量

- ▶ 他手里拿了一个**苹果**正在吃
- ▶ 他手里拿了一个**苹果**然后插上了充电器

$\mathbf{u}(\text{苹果}_1)$ $\mathbf{u}(\text{苹果}_2)$...

1. 没法提前知道每个词具体不同意思的数量
2. 没法提前知道当前句子中的词对应的意思是哪一个

4.1 动态词向量/预训练模型